Předmět – Neuronové sítě

Ročníková práce

Řízení laboratorního modelu G.U.N.T. RT 050

Ing. Mariška Martin
15.6.2013

Obsah

Seznam symbolů a zkratek

DIC Direct inverse control
IMC Internal model kontrol
MSE Mean Square Error

Úvod

Ročníková práce mádva hlavní cíle. Za prvé je třeba namodelovat optimální dynamický neuronový model laboratorního modelu motoru GUNT RT 050. Za druhé pomocí dvou metod řízení automaticky řídit otáčky modelu motoru. Požadované metody řízení jsou:

- Přímé inverzní řízení pomocí inverzní neuronové sítě (DIC – Direct Inverse Control)
- Řízení s vnitřním modelem pomocí inverzní neuronové sítě a dynamického neuronového modelu soustavy (IMC – InternalModel Control)

Jednotlivé metody řízení jsou popsány a vysvětleny například v publikacích [1], [2]. Způsob tvorby dynamického neuronového modelu je popsán v publikaci [1].

Obecné informace o modelu a měření

Laboratorní vybavení GUNT RT 050 má určeny pro řízení počítačem vstupní napětí v rozmezí 0V až 5V a na výstupu ze snímače otáček je výstupní napětí v rozmezí 0V až 10V. Pro jeho řízení je v prostředí Simulink vytvořen a předem připraven model a dynamická knihovna. Tento předpřipravený model byl použit jak pro sběr dat, tak i pro následné řízení soustavy.

Obrázek 1 – Reálný model motoru G.U.N.T. RT 050 [zdroj: www.gunt.de]

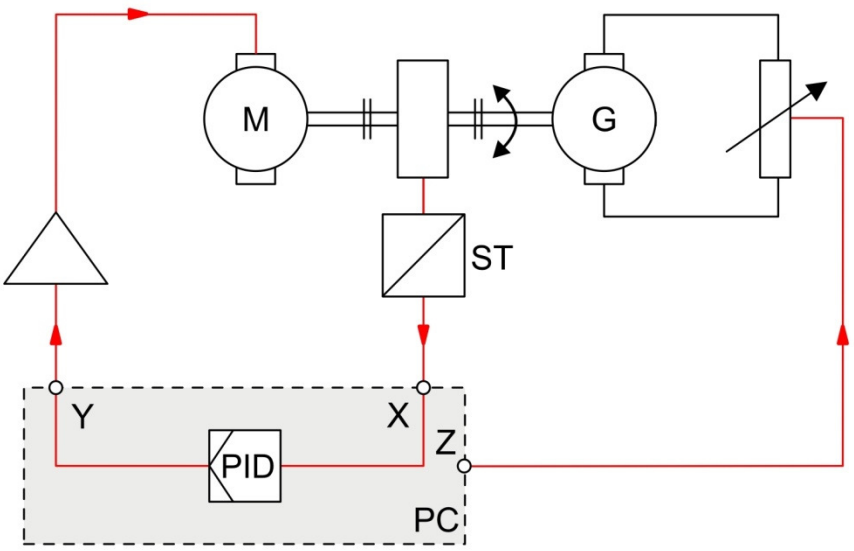

Obrázek 2 – Schéma zapojení s PC udávané pro model G.U.N.T RT 050 [zdroj: www.gunt.de]

Měření výstupních a vstupních parametrů je, již na úrovni modulu v simulinku, normalizováno na interval <-1, 1>. Proto se v celý projekt zmiňuje pouze o rozsazích -1, 1, tedy převedený vstupní rozsah napětí z <0, 5> V a výstupní rozsah napětí <0, 10> V. Oba jsou převedeny pomocí metody zvané „RangeNormalization“ (rozsahová normalizace). Ta umožňuje určitý rozsah hodnot mapovat na jiný rozsah hodnot.

Rozsahová normalizace: $f(x) = \frac{(x-d_L)(n_H-n_L)}{d_H-d_L} + n_L$

Rozsahová denormalizace: $f(x) = \frac{(d_L-d_H)\,x - (n_H \cdot n_L) + d_H \cdot n_L}{n_L-n_H}$

Kde n_H, n_L je normalizovaná maximální, minimální hodnota a d_H, d_L je maximální, minimální hodnota původního rozsahu. Více v [3].

Optimální dynamický neuronový model soustavy

Zadání

Navrhněte optimální dynamický neuronový model soustavy pro řízení otáček G.U.N.T. RT 050. Neuvažujte zátěž motoru. Kritérium optimality modelu definujte a jeho definici vysvětlete. Verifikaci neuronového modelu proveďte podle zapojení na obr. 1 pro průběh vstupu u podle obr. 2.

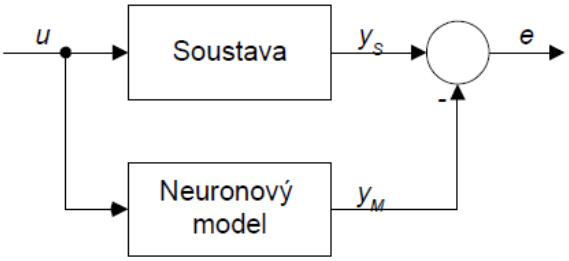

Obr. 1 Verifikace neuronového modelu

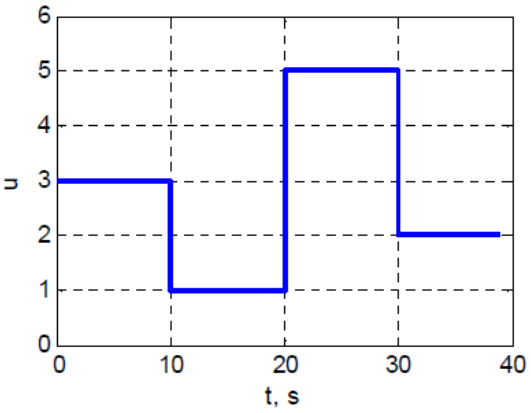

Obr. 2 Průběh vstupu pro verifikaci

Kritérium optimality

Definice optimality sítě je daná touto kriteriální funkcí:

$$Kr = \log\left(\frac{\sum_{k=1}^{N}(y(k) - y_{NS}(k))^2}{N}\right) + \frac{N_n}{100}$$

kde $y$je skutečné výstupní napětí, y_{NS} je výstupní napětí stanovené neuronovou sítí, N je počet vzorků pro test a $N_n$je celkový počet neuronů v použité neuronové síti.

Cílem optimalizace, podle tohoto kritéria, je tedy co nejpřesnější odhad výstupních hodnot vůči reálnému průběhu výstupu (první část kriteriálního vzorce) a zároveň minimalizujeme počet neuronů obsažených v neuronové síti (zachováme tím i vlastnost generalizace sítě). Kriteriální funkci budeme tedy minimalizovat.

Identifikace a volba vzorkovací frekvence

Prvnímvoleným parametrem pro nasnímání dat, které budou dále zpracovávány, je vzorkovací perioda a předpoklad jakého řádu je zkoumaný systém. Volba těchto dvou parametrů ovlivňuje následný model systému.V rámci konzultace ohledně snímání dat, bylo doporučeno, aby počet nasnímaných dat byl mezi 15-20 vzorky (informace je odvozena ze zkušenosti) na přechod soustavy znovu do ustáleného stavu po skokové změně na vstupu. Z přiloženého obrázku níže je vidět odezva na definovaný skok vstupního napětí.

Doba od začátku reakce až do ustálení trvá zhruba 15 sekund (odečteno z grafu viz. Obrázek 3). Tedy pro splnění požadavku 20 hodnot na skok je výpočet vzorkovací periody:

$$T_s = \frac{15}{20} = 0.75$$

Dále řád soustavy je také odvozen z grafu na obrázku 3. U soustav druhého a vyššího řádu je známé, že se na začátku grafu objeví doba průtahu. Existence doby průtahu indikuje systém minimálně druhého řádu,proto pro rovnice a trénování modelu je jako výchozí řád soustavy nejprve předpokládán druhý řád soustavy.

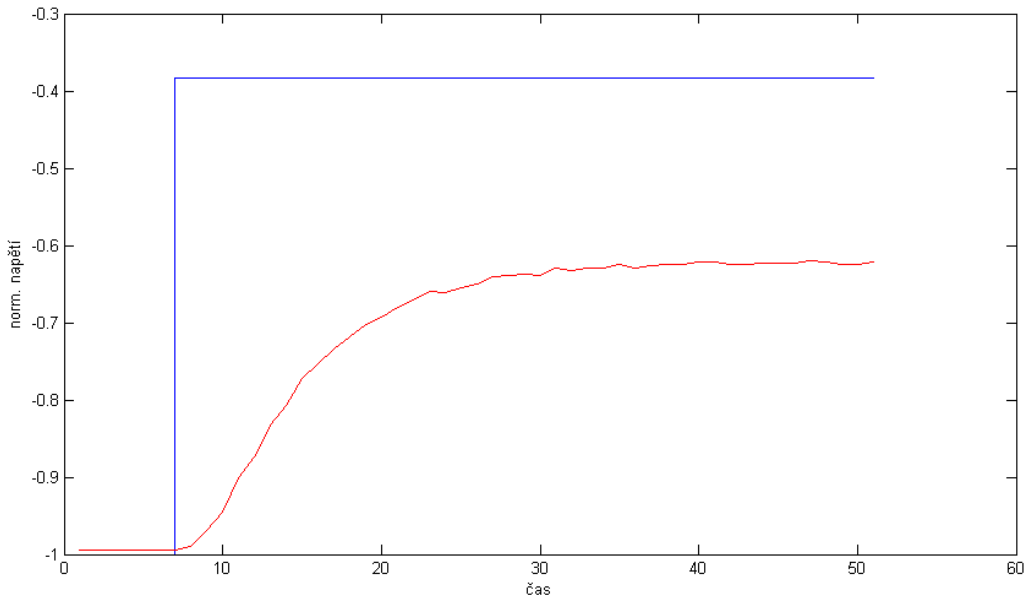

Obrázek 3 – reakce systému na vstupní skok

Nalezení optimálního modelu

Cílem této kapitoly je popsat postup nalezení optimálního neuronového modelu, kde míra optimality je definována kriteriální funkcí.

Naměřená množina dat

Celá množina naměřených dat se měřila cca 60 minut. A zapojený model měření v Simulinku vypadal následovně.

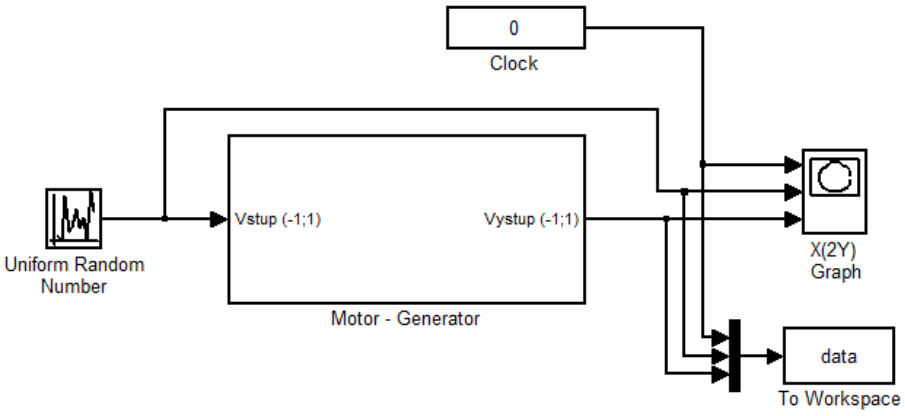

Obrázek 4 – Simulink schéma pro měření dat reálného systému

Průběh celé naměřené množiny je zobrazen níže, aby bylo vizuálně kontrolovatelné, že byl proměřen vhodně celý pracovní prostor systému. Volba vstupního signálu byla volena pseudonáhodně pomocí bloku „Uniform Random Number“ (seed = 615482, min = -1, max = 1).

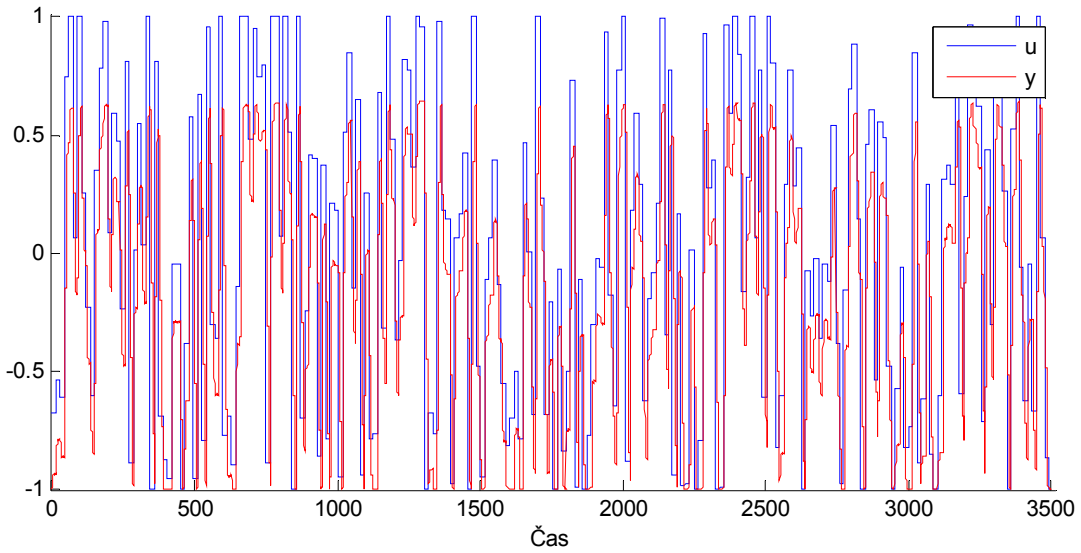

Obrázek 5 – Celá naměřená množina dat

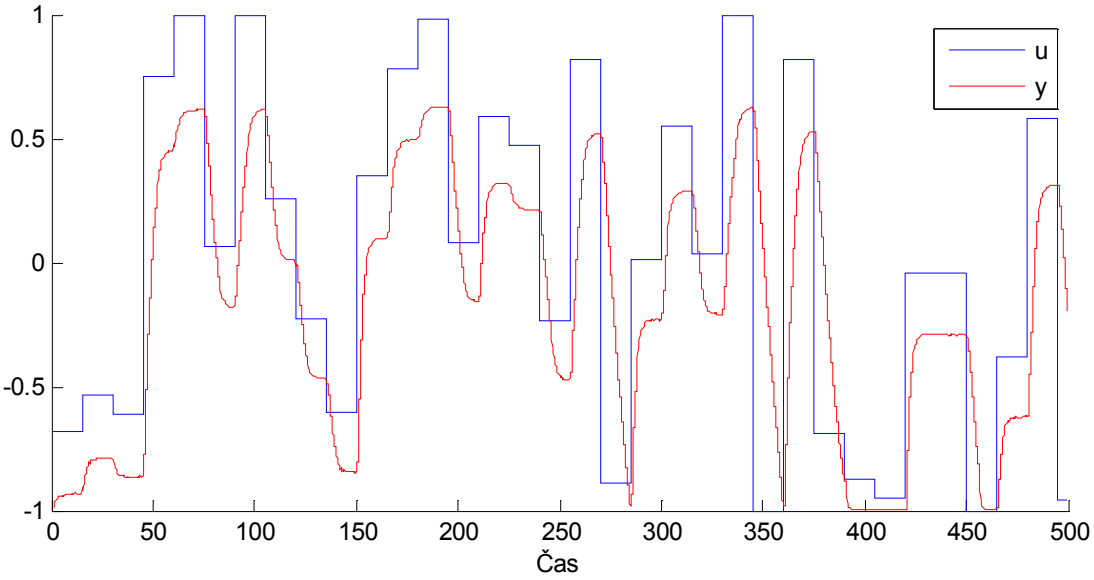

Obrázek 6 – Detail začátku naměřené množiny dat

Trénování neuronové sítě

Trénování neuronové sítě proběhlo na vybrané podmnožině naměřených dat. Množina vypadala následovně viz. Obrázek 7 a měla 600 hodnot.

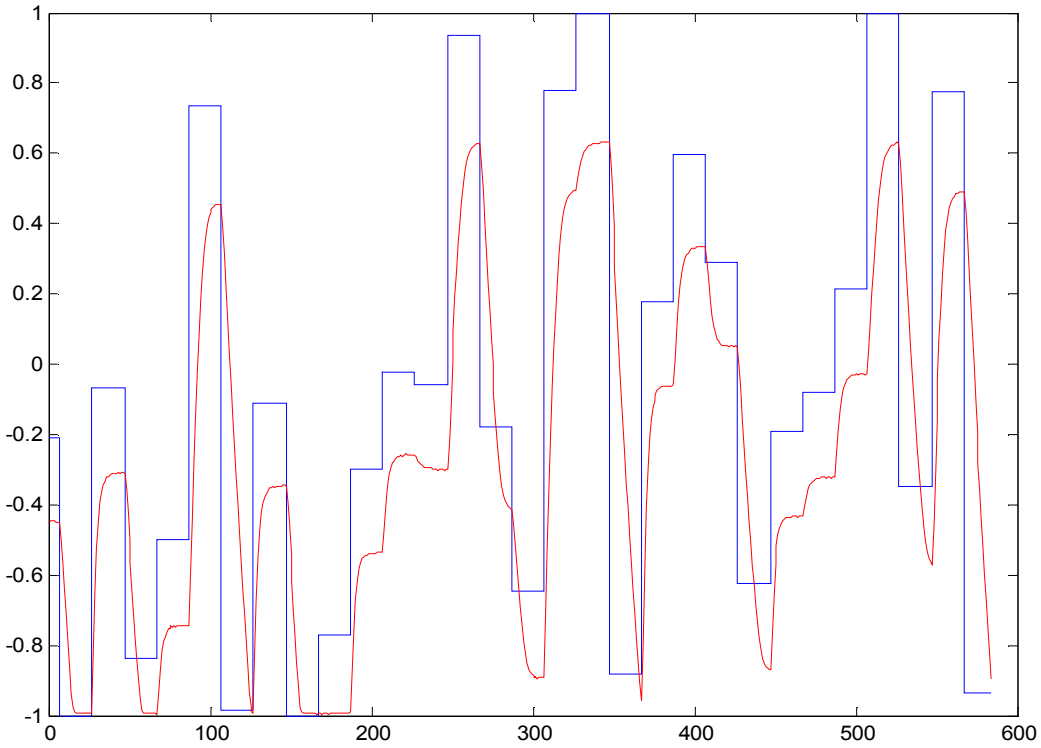

Obrázek 7 – Trénovací množina

Pro nalezení optimálního modelu byl zhotoven skript, který hledal vhodnou topologii a opakoval stejný scénář trénování několikrát po sobě (s jinými počátečními podmínkami pro neuronovou síť), aby bylo možné zobrazit i průměrné hodnoty kritéria. Ve výsledcích bude zobrazen krabicový graf, který vyjadřuje nejvhodnější topologii pro tento systém.

Algoritmus hledání zajišťuje uložení dat i s neuronovou sítí. Skript ukládá data, pouze pokud nalezne model s lepším výsledkem kriteriální funkce. Skript je přiložen v příloze A.

Pro trénování neuronové sítě byla sestavena vstupní množina dat, vycházející z diferenciální rovnice pro soustavu druhého řádu. Víc informací o diskrétním popisu soustav v [1]. Obecná rovnice pro soustavu druhého řádu vypadá následovně.

$$y(k+1) = \varphi[y(k), y(k-1), u(k), u(k-1)]$$

Z tohoto vyplývá, že cíle trénování budou hodnoty na pozici $y(k+1)$ a vstupy pro trénování budou hodnoty$y(k), y(k-1), u(k), u(k-1)$ v uvedeném pořadí. Následuje skript pro vytvoření vstupů a cílů pro trénování z výchozí naměřené množiny dat.

```
% pole u, y jsou výchozí naměřené vektory dat
%vytvorit vstupy / inputs
inputs = [y(2:end-1); y(1:end-2); u(2:end-1); u(1:end-2)];
%vytvorit cíle / targets
targets = y(3:end);
```

Pro zjednodušení používání neuronového modelu v Simulinku, je vytvořen blok subsystému. Schéma vnitřního zapojení je na obrázku níže. Tento blok se pak používá dále ve schématech pro řízení.

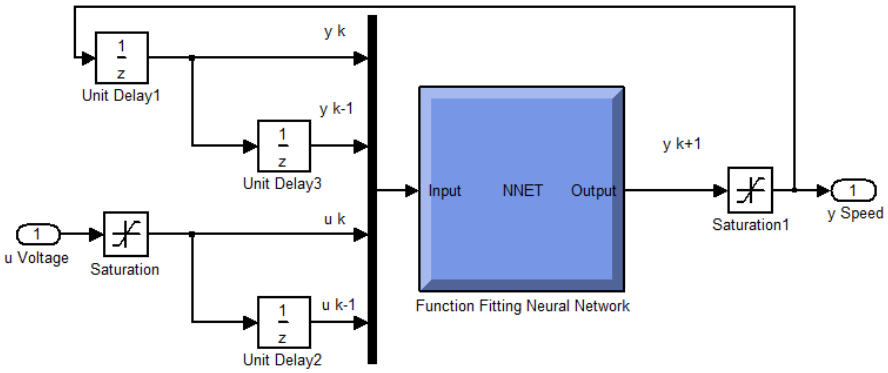

Obrázek 8 – Schéma vnitřního zapojení bloku pro neuronový model

Výsledky

Tabulka s přehledem topologií a nejlepších hodnot kriterií z 10 replikací pro danou topologii.

Tabulka 1 – Porovnání hodnot kritérií pro různé topologie

Topologie	*Nejmenší hodnota kritéria (z 10 replikací)*
4 – 5 – 1	-4.4056
4 – 10 – 1	-4.5718
4 – 13 – 1	-4.5880
4 – 15 – 1	-4.5758
4 – 4 – 3 – 1	-4.5390
4 – 5 – 5 – 1	-4.5232
4 – 7 – 7 – 1	-4.6122
4 – 8 – 1	-4.5085

Krabicový graf s hodnotami kritéria pro jednotlivé topologie. Pokus byl proveden pro každou topologii v 10 replikacích (pokus se stejným scénářem) a ve spodní části je topologie označena počtem neuronů ve skryté vrstvě.

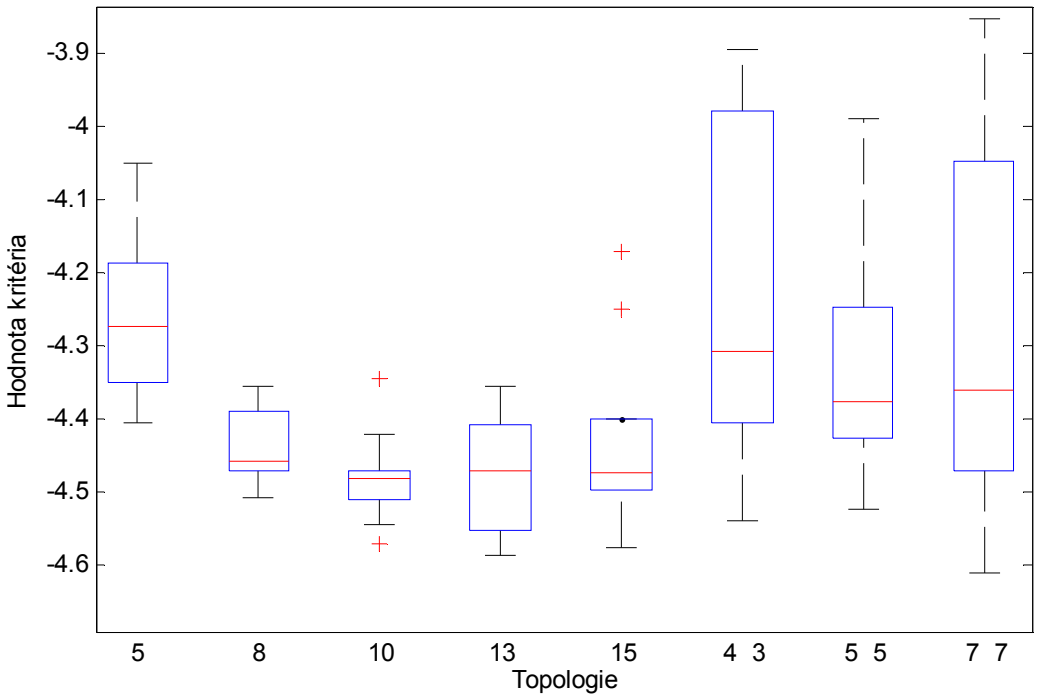

Obrázek 9 – Krabicový graf kriterií podle typu topologie

Z krabicového grafu plyne, že nejvhodnější topologie je s 10 skrytými neurony v jedné skryté vrstvě. Průměrně poskytuje nejnižší hodnoty kriteriální funkce.

Problémy a doporučení

V průběhu pokusů a testování neuronové sítě jsem došel k závěru (který je ověřitelný měřením), že pokud se trénuje dynamický model z mnoha naměřených vzorků (2000 vzorků a více), tak je mnohem obtížnější jednak natrénovat neuronovou síť, ale výsledný model je i přeučený a není snadné ho následně dobře řídit. Pro některé hladiny žádané veličiny vracel neuronový model stále malinko odlišné veličiny a tím se stále projevovalo mírné kolísání kolem požadované hodnoty.

Verifikace dynamického modelu

Cílem verifikace dynamického neuronového modelu, je porovnat průběhy modelu s reálnou soustavou. Průběh žádané veličiny je uveden v zadání. A jednotlivé naměřené hodnoty jsou vyneseny do grafu na obrázku níže.

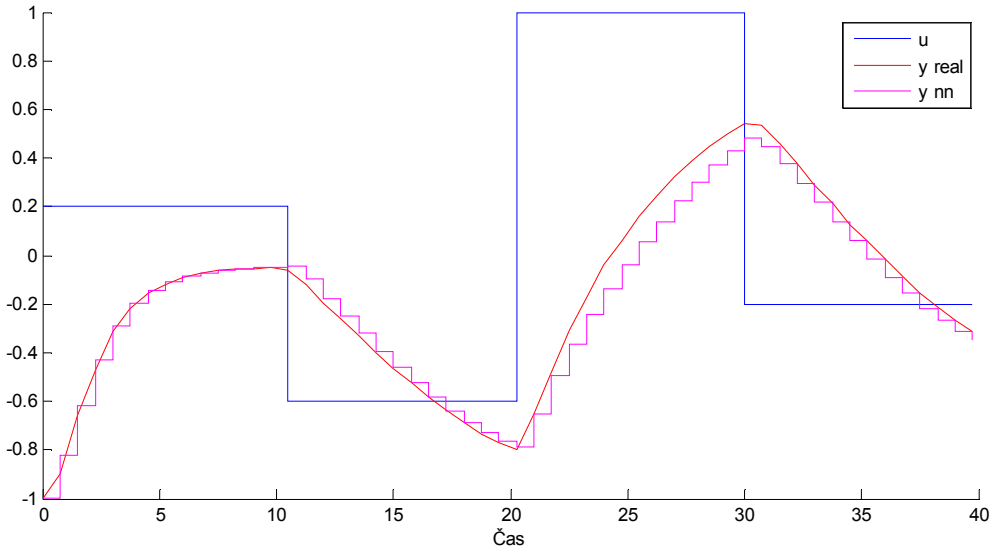

Obrázek 10 – Porovnání průběhu neuronového modelu s reálnou soustavou

Jako číselné vyjádření kvality je ještě uvedena hodnota MSE (často se používá pro porovnávání i v jiných publikacích).

$$MSE = \frac{1}{n}\sum_{i=1}^{n}\left(\boldsymbol{y}_i^{real} - \boldsymbol{y}_i^{nn}\right)^2 = 0.0029$$

Automatické řízení otáček soustavy

Zadání

Navrhněte následující způsoby automatického řízení soustavy pro řízení otáček G.U.N.T. RT 050.

a) Přímé inverzní řízení pomocí inverzní neuronové sítě

b) Řízení s vnitřním modelem pomocí inverzní neuronové sítě a dynamického neuronového modelu soustavy

Výsledné regulátory otestujte pro průběh žádané hodnoty regulované veličiny *r* a poruchy *v* (zátěž motoru) uvedený na obr. 3. Dosažené regulační pochody porovnejte se simulacemi dosaženými pomocí neuronového modelu a výsledky diskutujte.

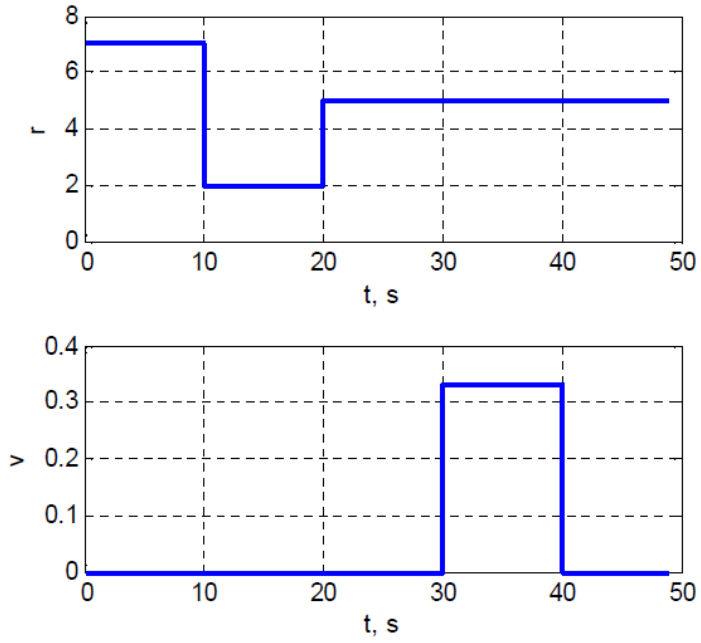

Obr. 3 Průběh žádané hodnoty a poruchy

Řízení metodou DIC

Obecný popis a východiska pro metodu přímého inverzního řízení (DIC) je například v publikaci [1], [2]. U obou metod je obecným problémem vytvoření inverzního modelu soustavy, protože u některých systémů nemusí být jednoduché jeho natrénování. Způsob jakým získat lepší množinu dat pro trénování je například danou soustavu řídit pomocí vhodné varianty diskrétního PID regulátoru.

Pro natrénování inverzního modelu soustavy byla použita data z reálné soustavy řízené pomocí jednoduchého diskrétního PI regulátoru (P = 0.2, I = 0.2) s předcházením tzv. „wind-up“ efektu za pomocí metody „back-calculation“. Sesbírány byly tedy hodnoty vstupu až na výstupu PI regulátoru a jako výstupní hodnoty se ukládala data na výstupu ze soustavy. Pro názornější představu je zobrazeno schéma zapojení ze Simulinku.

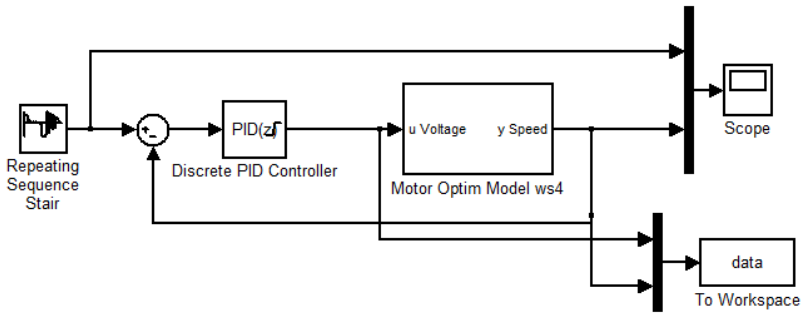

Obrázek 11 – Simulink schéma měření dat pro inverzi

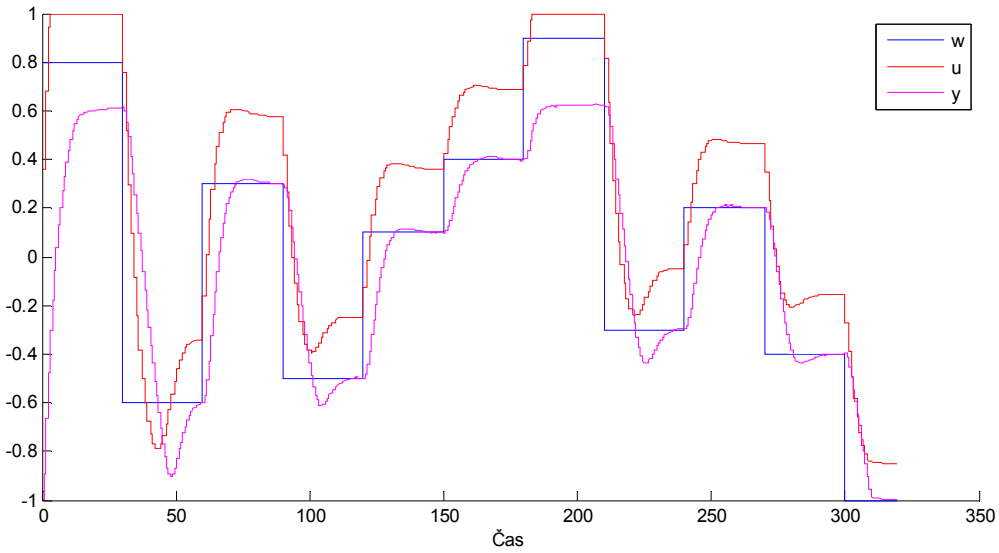

Obrázek 12 – Naměřená data pro trénování inverze

Pro trénování inverze byl zvolen stejný postup jako u hledání optimálního dynamického neuronového modelu. Struktura neuronového modelu byla zvolena na začátku jako nejjednodušší inverze soustavy prvního řádu. Přesná teoretická východiska jsou v [1]. Tedy rovnice pro trénování vypadá takto:

$$u(k) = \varphi^{-1}[y(k+1), y(k)]$$

Kde na levé straně rovnice jsou cíle pro trénování tedy $u(k)$. Funkceφ^{-1} představuje inverzní funkci, kterou se má aproximovat neuronová síť a vstupy pro trénování jsou $y(k+1),\ y(k)$.

```
% pole u, y jsou výchozí naměřené vektory dat
% vytvorit vstupy / inputs
inputs = [y(2:end); y(1:end-1)];
%vytvorit cíle / targets
targets = u(1:end-1);
```

Dále byl proveden i pokus s inverzí nad soustavou druhého řádu, ale významnou změnu to pro řízení nepřineslo. Pokud se vycházelo ze soustavy druhéhořádu, tak naopak bylo těžší natrénovat neuronovou síť s dostatečnou přesností a následně byl regulační pochod náchylnější na menší změny (co může v realitě způsobovat i rušení a znatelným způsobem ovlivňovat regulační pochod).

Následně bylo provedeno hledání optimálního inverzního modelu a nejlepší kriteriální hodnotu měla topologie 2 – 5 – 5 – 1 s hodnotou kritéria -2.6765. Pro názornost je na obrázku níže zobrazeno porovnání originálního a aproximovaného průběhu neuronovou sítí a krabicový graf pro porovnání vlivu různých topologií na trénování.

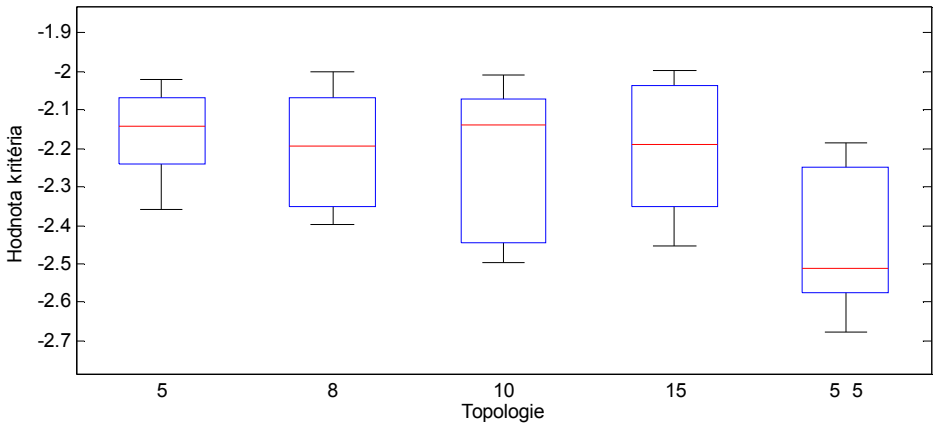

Obrázek 13 – Krabicový graf pro porovnání hodnot kritéria pro různé topologie

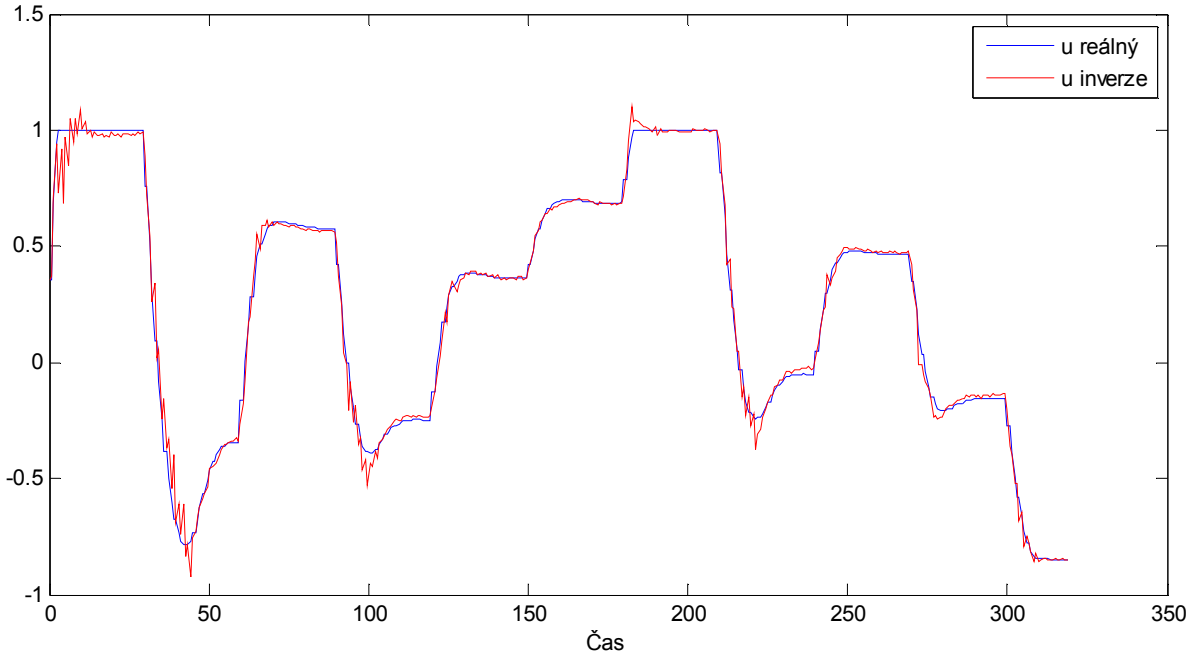

Obrázek 14 – Porovnání průběhu u_{real} (pro reálný systém) a u_{inn} (pro výstup z inverzní sítě)

Pro řízení metodou DIC se zapojuje inverzní model předřazením před řízenou soustavu, více informací o metodě DIC a zapojení v [1], [2]. Následuje nejprve schéma zapojení subsystému inverzního neuronového modelu a následně schéma zapojení celé soustavy pro experimenty v prostředí simulink.

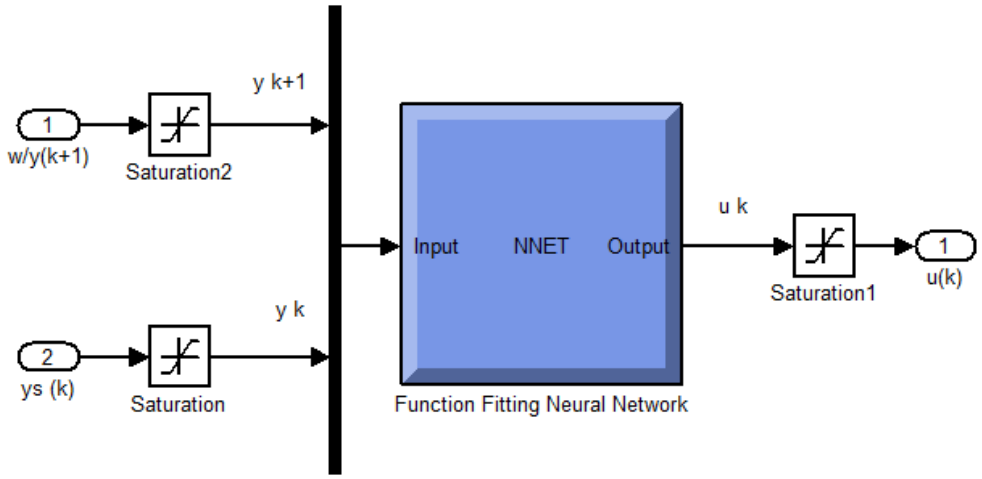

Obrázek 15 – Schéma zapojení bloku susbsytému s inverzním modelem

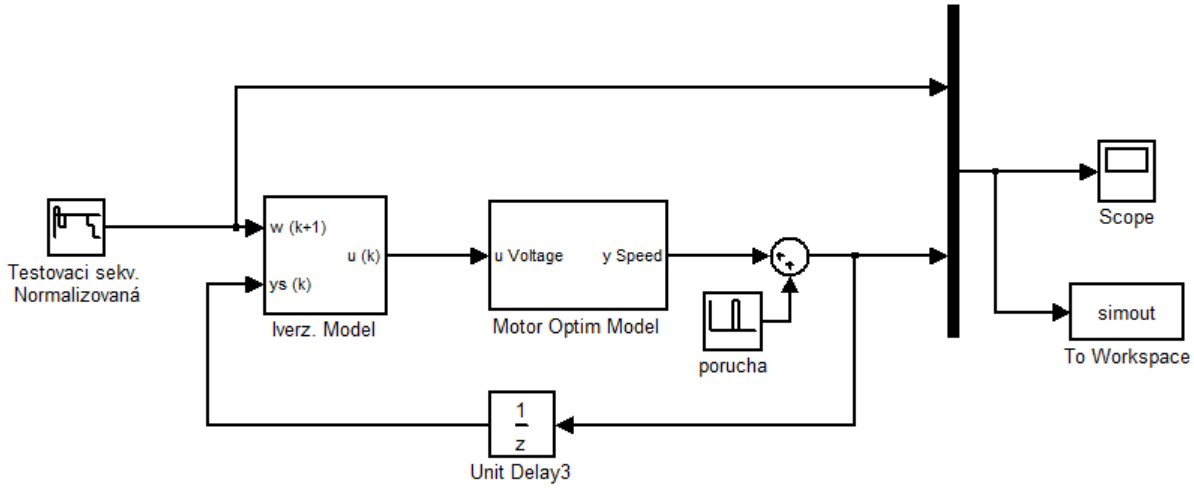

Obrázek 16 – Schéma zapojení regulace pomocí metody DIC

Podle zadání bylo řízení provedeno řízení modelu a soustavy na testovacím průběhu definovaném v zadání.

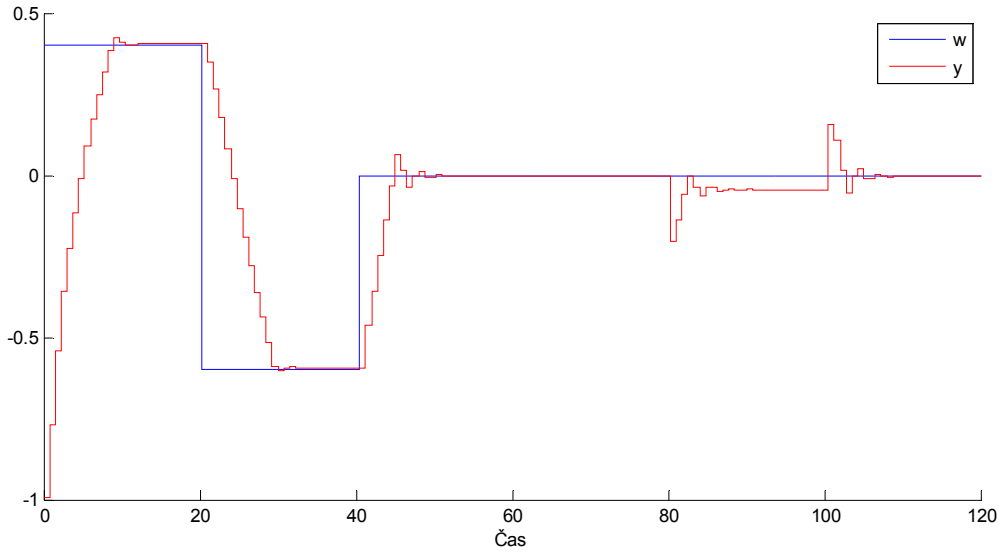

Obrázek 17 – Test řízení metodou DIC na testovacím průběhu s neuronovým modelem

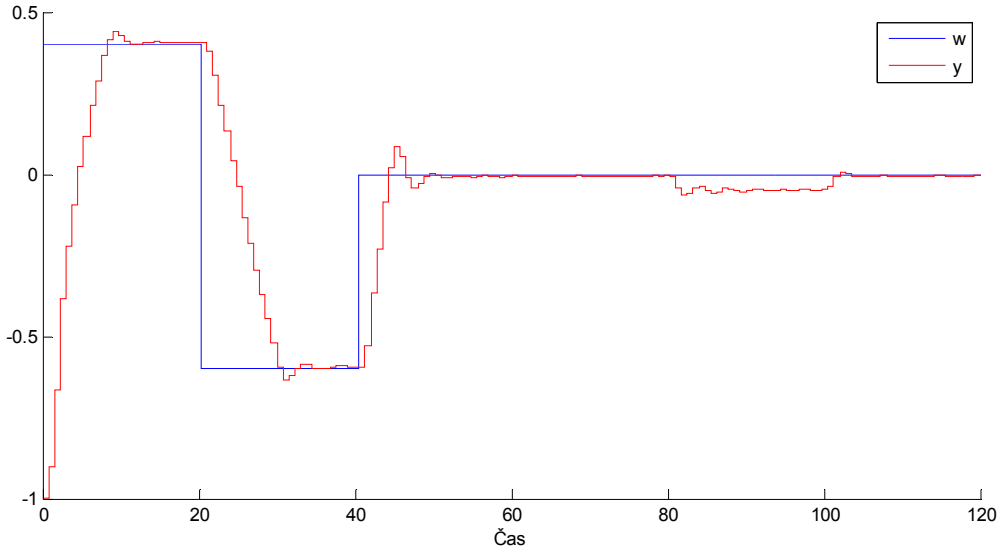

Obrázek 18 – Test řízení metodou DIC na testovacím průběhu s reálnou soustavou

Řízení metodou IMC

Obecný popis a teoretická východiska pro metodu řízení pomocí vnitřního modelu (IMC) je například v publikaci [1], [2]. Pro natrénování inverzního modelu soustavy byl použit stejný postup jako u metody DIC v předešlé kapitole. Schéma metody IMC je zobrazeno na obr. 19.

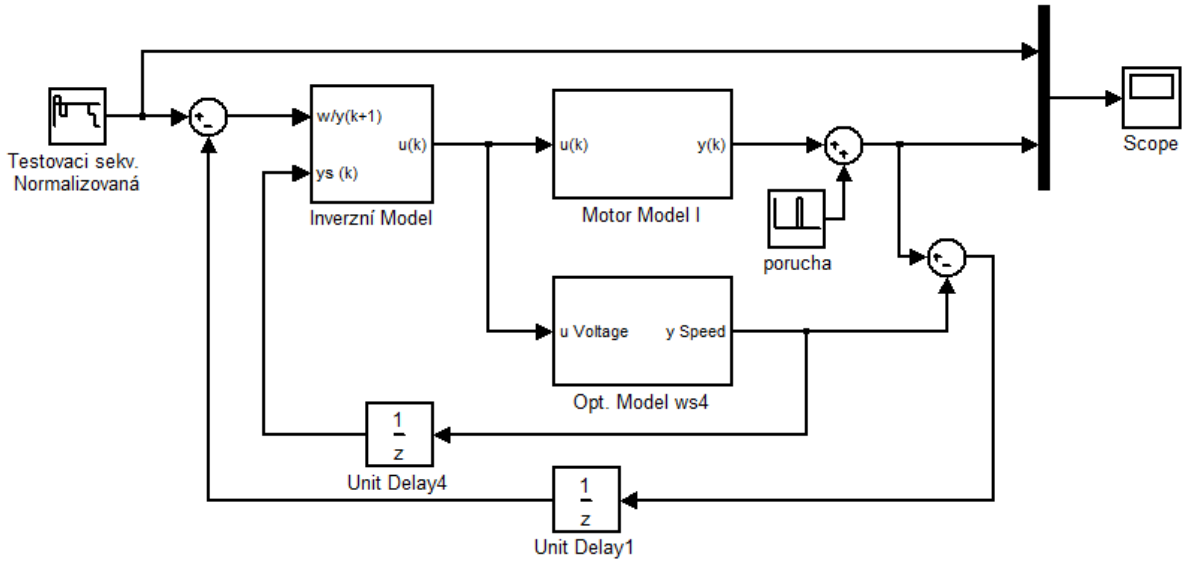

Obrázek 19 – Schéma zapojení bloků v simulinku pro metodu IMC

Byl nejprve proveden test regulace na testovací sekvenci žádané veličiny pro řízení neuronového modelu za pomocí jiného neuronového modelu. Byl znovu natrénován, aby nevracel identická data. Až po tomto testu bylo nasazeno schéma na reálnou soustavu a blok „motor model“ byl nahrazen blokem pro práci s reálnou soustavou. Níže jsou uvedeny oba průběhy, jednou s neuronovým modelem a jednou pro řízení reálné soustavy.

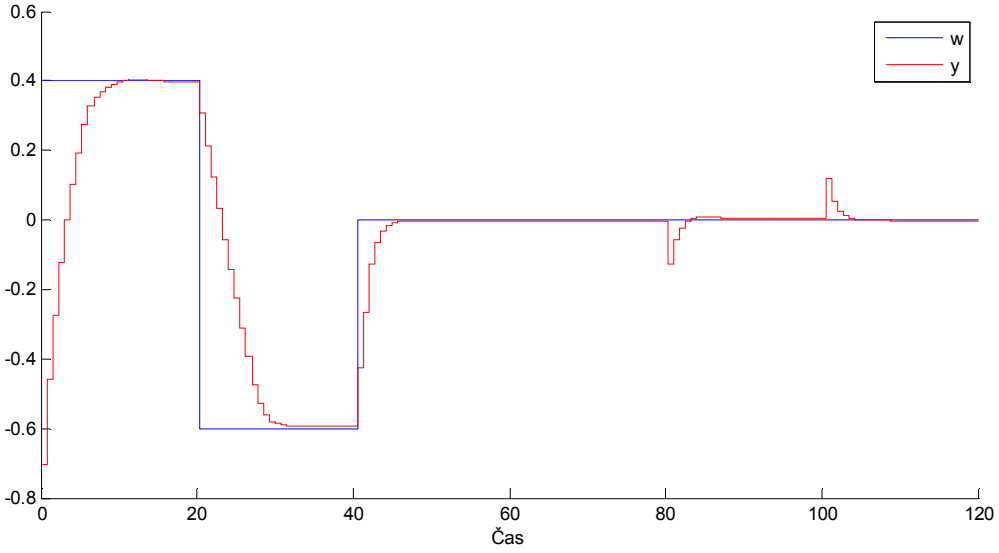

Obrázek 20 – Test řízení metodou IMC na testovacím průběhu s neuronovým modelem

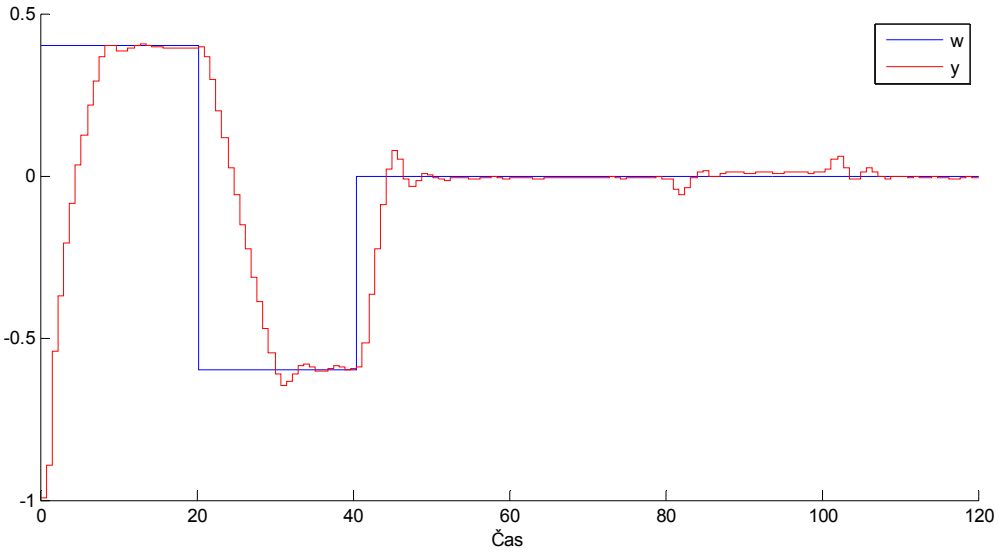

Obrázek 21 – Test řízení metodou IMC na testovacím průběhu s reálnou soustavou

Porovnání a diskuse výsledků metod řízení

V této kapitole budou porovnány obě zadané metody řízení. Porovnávány budou z pohledu řízení, tedy z pohledu reakce na změnu žádané veličiny a reakce na poruchy. Kvalita obou metod bude vyjádřena kvantitativně pomocí MSE.

Byl proveden experiment a naměřeny hodnoty regulačních pochodů pro obě metody s reálnou soustavou. Hodnoty jsou zobrazeny v grafu na obrázku níže.

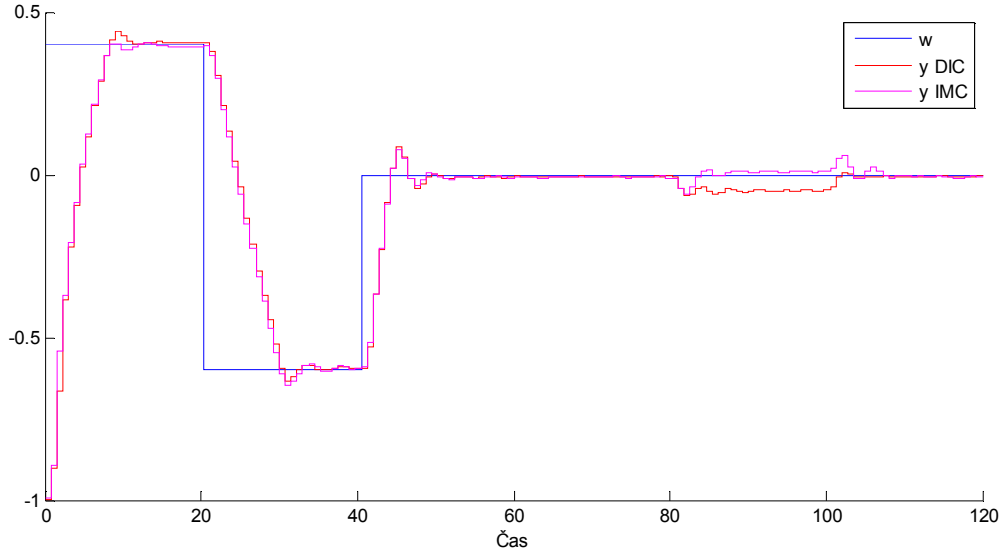

Obrázek 22 – Porovnání obou metod řízení (DIC s IMC) na reálné soustavě

Hodnota MSE číselně vyjadřuje, který regulační pochod se více přibližuje k žádané veličině (menší hodnota MSE znamená přesnější regulační pochod).

$$E_{DIC} = MSE(\boldsymbol{w} - \boldsymbol{y}_{DIC}) = 0.775$$

$$E_{IMC} = MSE(\boldsymbol{w} - \boldsymbol{y}_{IMC}) = 0.751$$

Kde $\boldsymbol{w}$ a $\boldsymbol{y}$ jsou příslušné vektory naměřených hodnot. Pro výpočet byla použita funkce poskytnutá prostředím Matlab. Funkce má název *mse* a používá se stejným způsobem, jako je uveden výpočet výše. Z číselného porovnání lze říci, že přesnější regulační pochod poskytuje metoda IMC.

Největší výhodou metody IMC oproti DIC, je zpětná vazba a tedy již teoretického hlediska je IMC schopna na základě zpětné vazby upravit akční veličinu tak, aby se případný poruchový signál anuloval. Poruchový signál je pro metodu DIC případem, kdy se náhle změní parametry soustavy a regulátor se o tom nedozví. Z principu lze u metody DIC předpokládat velkou náchylnost na poruchové signály. Druhé hledisko je, že metoda IMC vyžaduje jak inverzní model soustavy, tak i dopředný dynamický model soustavy. Je tedy mnohem náročnější na realizaci.

Závěr

Byl zhotoven optimální neuronový model laboratorního systému GUNT RT 050,realizovány a otestovány dvě metody řízení (DIC, IMC). Vhodnější metodou pro řízení soustavy je metoda IMC, protože je méně náchylná na poruchové signály a vhodně upravuje regulaci díky zpětné vazbě. V teoretické i praktickém porovnání byla lepší metoda IMC.

V průběhu práce byl nalezen problém, že při velkém množství vzorků, pro trénování neuronového modelu systému a pro trénování inverze, je obtížné dobře natrénovat neuronovou síť, tak aby dostatečně aproximovala reálný systém a nebyla přeučená. V průběhu trénování a testování se tedy ukázalo, že je vhodnější brát množiny o 600 až 1500 vzorcích. Vzorky obsahovaly zhruba 10 až 15 změn vstupní veličiny. Perioda mezi změnami byla volena přibližně tak, aby se soustava stihla na výstupu ustálit.

Literatura

[1] DOLEŽEL, Petr. „Umělé neuronové sítě v modelování a řízení kontinuálního bioreaktoru“. Diplomová práce. Univerzita Pardubice. 2008.

[2] Direct Inverse Control&Internal Model Control. In: [online]. [cit. 2013-06-15]. Dostupné z: https://courses.cs.ut.ee/2008/modelling-and-control/slides/dic-and-imc.pdf

[3] RangeNormalization. In: [online]. [cit. 2013-06-15]. Dostupné z: http://www.heatonresearch.com/wiki/Range_Normalization

Přílohy

Příloha A – Optimalizační skript

```
% script for discover optimal dynamic neural model of motor

% keep for all test value of criteria, performance, ...
% for each topology do 5 tests
% save better model tagged with criteria value..

inputs = inputs;
targets = targets;
startTime = now();
topologyPatterns = {5; 8; 10; 13; 15; [4 3];[5 5]; [7 7]}; % 15; 20; [8 8]; [5 5]  [11 15 18
20 25]; %[11 15 18 20 22 25 29];
replications = 10;
maxTrainTimeInSec = 1*60;
count = 1;
optimizedTopology = cell(replications*length(topologyPatterns),1);
for k = 1:length(topologyPatterns)
    for j = 1:replications
        optimizedTopology{count} = topologyPatterns{k};
        count = count + 1;
    end
end
criterias = ones(length(optimizedTopology), 1).*99;
optimizeData = cell(length(optimizedTopology), 2);
%vyrobit slozku pro vysledky
folderName = ['vysledky_' datestr(startTime,'yyyy-mm-dd_HHMMss')];
mkdir(folderName);

%vlastni cyklus pro uceni a ukladani nejlepsich vysledku
for k = 1:length(optimizedTopology)
    [net, trainResults] = learnNet(inputs, targets, optimizedTopology{k}, maxTrainTimeInSec);
    crit = Criteria(net, inputs, targets);
    critValue = crit.getValue(); %vypocet kriteria [minimalizujeme]
    simplefitOutputs = net(inputs); %simulace hodnot
    actPerformance = perform(net, targets, simplefitOutputs);
    disp([num2str(k) '. top/perf/criteria [' num2str(optimizedTopology{k}) ', '
num2str(actPerformance) ', ' num2str(critValue) ']']);
    if(critValue < min(criterias))
        save([folderName '/workspace_' num2str(critValue) '.mat']);
        disp('> model saved...');
    end
    criterias(k) = critValue;
    optimizeData{k,1} = num2str(optimizedTopology{k});
    optimizeData{k,2} = actPerformance;
    optimizeData{k,3} = critValue;
    optimizeData{k,4} = trainResults.perf;
    save([folderName '/measureInfo'], 'optimizeData');
    disp('> info data saved...');
end
[~, idx] = min(criterias);
disp(['best model is at ' num2str(idx)]);
```

```
function [net, trainResults] = learnNet(inputs, targets, topology, maxTrainTime)
% povinne jsou prvni dva argumenty "inputs, targets"

clear('net');
net = fitnet(topology);
% Setup Division of Data for Training, Validation, Testing
net.divideParam.trainRatio = 80/100;
net.divideParam.valRatio = 10/100;
net.divideParam.testRatio = 10/100;
% nezobrazovat okno uceni
net.trainParam.showWindow = false;

net.trainParam.time = maxTrainTime;
net.trainParam.epochs = 1000;
net.trainParam.max_fail = 100;

% Train the Network
[net, trainResults] = train(net, inputs, targets);
```